İNTİHAL KONTROL UYGULAMASI

Furkan BARAN

11-2023

İçerik Tablosu

1. Giriş

Bu uygulamada **Python** programlama dilini kullanarak bir metni, verilecek diğer metinler ile karşılaştırarak aralarındaki **benzerliklerin tespit edilmesi ve işaretlenmesi** hedeflenmiştir. Aynı zamanda kullancıların dosya seçimlerini rahatlıkla yapabilmeleri, intihal olarak işaretlenen kısımları görsel olarak ayırt edici şekilde görebilmeleri, intihallerin hangi dosyanın hangi cümlesinden yapıldığına kadar ayrıntılı gösterimlere erişebilmesi için bir **web arayüzü** tasarlanması ihtiyaç olarak görülmüştür.

İlgili ihtiyaçlar göz önünde bulundurulduğunda, uygulama için **Django** veya **Flask** Python web çerçevelerinden birinin kullanılması uygun görülmüştür. Daha sonra sahip olduğu basitlik, esneklik ve özgürlük özellikleri nedeniyle **Flask** çerçevesinin kullanılmasına karar verilmiştir.

2. İntihal Tespitinde Kullanılacak Algoritma

İntihal tespiti için çeşitli kütüphaneler, yapay zeka modelleri araştırılmış ve test edilmiştir. Yapılan araştırma ve testler sonucu, bu kütüphaneler ve modellerin hem dil konusunda esneklik sağlamaması, hem de istenen seviyede hızlı sonuçlar verememesi nedeniyle uygulamaya özel algoritmaya sahip bir fonksiyon ile intihallerin tespit ve işaretlenmesinin yapılmasına karar verildi.

2.1. “İntihal”in Tanımı

Uygulamanın algoritmasında intihal olarak işaretlenme koşulları belirlenmiştir. Buna göre;
Verilen metinde ardışık N adet kelimenin, diğer metinler içinde de aralarında başka kelime olmaksızın ardışık şekilde aynı sırayla bulunması, intihal sayılacaktır.

2.2. “Kelime”nin Tanımı

Uygulamanın algoritmasında intihal olarak işaretlenme koşullarında, bir karakter dizisinin “kelime” olarak sayılması koşulları belirlenmiştir. Buna göre;
Metindeki karakter dizilerinden, aralarında en az bir boşluk veya yeni satır karakteri olanlar birer kelime sayılacaktır. Kelimeler

2.3. “N sayısı”nın Tanımı

N sayısı varsayılan ve en az 3 olmak üzere bir tam sayı olmalı ve kullanıcıdan alınabilmelidir. N saysının büyüklüğü, intihal sayımına töleransın artmasına sebep olur, düşüklüğü ise töleransın çok azalmasına ve intihal oranının yüksek bulunmasına sebep olabilir.

2.4. Kelimelerin Karşılaştırılması

- Kelimeler karşılaştırılırken, içerdikleri tüm harfler küçük harfe çevrilir. Böylece büyük-küçük harfe karşı duyarsızlaşılır.
- Kelime içinde çeşitli noktalama işaretlerinin olması durumunda noktalama işaretlerinin kaldırılarak birleştirilmiş hali karşılaştırma için ele alınır.

Örnek metin: **Pendikspor’un 2023-2024 sezonunda şampiyon olma ihtimali kalmadı.**
Karşılaştırma için kullanılacak çıktı: **pendiksporun 20232024 sezonunda şampiyon olma ihtimali kalmadı**

2.5. Algoritma

Bir kelimenin veya kelime grubunun intihal olarak işaretlenmesi ile ilgili yukarda verilen koşullara göre, Python kullanılarak bu algoritmanın gerçeklenmesi için için şu şekilde bir sözde kod (psödokod) hazırlanmıştır:

- Kontrole başlamadan önce kelimeleri uygun formata dönüştürüp sakla.
- Kontrol edilecek metnin ilk kelimesinden başlayarak döngü şeklinde ardışık N adet kelimeyi ele al,
    - Bu kelimeleri verilen kaynak metinler arasında aramak için aynı şekilde her kaynak dosyası için;
        - İlk kelimeden başlayatak döngü şeklinde N ardışık kelimeyi ele al
            - eğer her iki kelime grubu da aynı ise, her iki gruptaki kelimeleri de intihal olarak işaretle
        - kaynak dosyasından ele alınan kelime grubundan ilk kelimeyi çıkar, metindeki sonraki kelimeyi grubun sonuna ekle ve karşılaştırmalara devam et.
    - Kontrol edilecek metnin ele alınan kelime grubundan ilk kelimeyi çıkar, metindeki sonraki kelimeyi grubun sonuna ekle ve karşılaştırmalara devam et.

2.6. Kontrol Algoritmasının Python Koduyla Fonksiyon Olarak Yazılması

```
main_text = []      # asıl metin listesi      [kelime]
main_gui = []       # asıl metnin gui'de kullanılmak üzere saklanan ve işaretlerini tutan listesi
                      [kelime, intihalMi?, yeni satır var mı?]
source_texts = []   # kaynak metinlerin listesi   [dosya] [kelime]
source_gui = []     # kaynak metinlerin gui'de kullanılmak üzere saklanan ve işaretlerini tutan listesi
                      [dosya] [kelime, intihalMi?, yeni satır var mı?]

def kontrol():
    N = 3 # varsayılan değer
    n = N - 1 # N sayının bir eksiği, eklenecek kelime ilk kelimeden N-1 kelime sonraki kelime olacaktır
    main_N= main_text[:N-1].copy() # ilk N-1 kelimeyi main_N listesine ekliyoruz, N tane eklememe sebebimiz
                                   # sonraki kelimenin döngüde eklenecek olmasıdır
    main_len = len(main_text)
    for id in range(main_len - n):
        main_N.append(main_text[id + n]) # main_N listesine sonraki kelimeyi ekliyoruz
        for file_id in range(len(source_texts)): # dosya sayısı kadar döngü
            for j in range(len(source_texts[file_id]) - n): # dosyadaki kelime sayısı-1 kadar döngü
                if main_N == source_texts[file_id][j:j+N]: # eğer main_N listesi, kaynak kelime listesinin
                                                           # ardışık N kelimesine eşitse
                    for k in range(N): # N kadar döngü şeklinde her kelimeyi işaretliyoruz
                        main_gui[id + k][1] = True # main_text'in arayüz için kullanılacak dönüştürülmemiş
                                                   # halini içeren listede, kelimenin 1. indisi True
                                                   # değerini(intihal) alıyor (0. indisi kelimeyi tutuyor)
                        source_gui[file_id][j + k][1]=1 # kaynak kelime listesinin arayüz için kullanılacak
                                                        # dönüştürülmemiş halini içeren listede, kelimenin 1.
                                                       # indisi 1 değerini (intihal) alıyor (0. indisi kelimeyi tutuyor)
        main_N.pop(0) # main_N listesinin ilk elemanını çıkarıyoruz,
                      # böylece yeni kelime eklenebilir hale geliyor
```

3. Dosyaların Okunması ve İşlenmesi

Asıl dosya ile kaynak dosyaların işlenişi ve sayıları farklı olduğundan her iki grup için ayrı fonksiyonlar kullanılması uygun görüldü. Ayrıca dosyalar kullanıcıdan web arayüzle alınacağından dosya nesneleri string listeleri olarak varsayıldı.

3.1. Asıl Dosyayı Okuma

Önceki listeler yeni okuma için temizlenir, dosya satır satır okunur, her satır kelimelere ayrılır, her kelime uygun formatlı haliyle uygun listeye eklenir, satır sonlarındaki kelimeler satır sonu olarak işaretlenir.

```
def dosya_oku(file_content):
    main_text.clear()
    main_gui.clear()
    text_lines = file_content.splitlines()
    word_id = 0
    for line in text_lines:
        for word in line.split():
            main_text.append(word.translate(str.maketrans('', '', r"""!"#$%&'()*+,-
./:;<=>?@[\]^_`{|}~‘’“”""")).lower())
            main_gui.append([word, False, False])
            word_id += 1
        main_gui[word_id - 1][2] = True
```

3.2. Kaynak Dosyaları Okuma

Listeler temizlenir, listelerde yeni dosyalar için yer açılır, döngü halinde her dosya ayrı ayrı, tek tek satırlar ve kelimelere ayrılarak okunur ve uygun listelere eklenir. Her dosyaya sırasına göre bir id verilmiş olur.

```
def dosyalar_oku(file_contents):
    source_gui.clear()
    source_texts.clear()
    file_id = 0
    file_dict.clear()
    for file_content in file_contents:
        source_texts.append([])
        source_gui.append([])
        text_lines = file_content.splitlines()
        word_id = 0
        for line in text_lines:
            for word in line.split():
                source_gui[file_id].append([word, 0, False])
                source_texts[file_id].append(word.translate(str.maketrans('', '', r"""!"#$%&'()*+,-
./:;<=>?@[\]^_`{|}~“”""")).lower())
                word_id += 1
            source_gui[file_id][word_id - 1][2] = True
        file_id += 1
```

4. Flask Web Çerçevesinin Kurulumu

Uygulamanın çıktılarını görüp test edebilmek için Flask ile web ortamına entegresine başlandı. Öncelikle bilgisayarda Flask'in kurulu olduğundan emin olmalıyız.

```
>> pip install Flask
```

Daha sonra açacağımız proje klasörü içinde "app.py" dosyası oluşturuyoruz:

```
from flask import Flask

app = Flask(__name__)
if __name__ == '__main__':
    app.run(debug=True)
```

4.1 Web Uygulumasının Anasayfa (index.html) Dosyasını Oluşturma

Kullanıcıları karşılayan, gerekli girdileri almak üzere kullanışlı bir arayüze sahip html sayfası oluşturulmalıdır. Ayrıca bu sayfa flask arkaplanıyla iletişimde olacaktır. Girilen dosyaları, arkaplanda python fonksiyonları ile işlenmek üzere sunucuya almalıdır. Bu html dosyası, 'templates' klasörü içinde bulunmalıdır.
Şimdilik işlevsel olarak test amaçlı basit bir arayüz ile kullanıcıdan metin dosyaları almak üzere bir sayfa hazılandı.

```
<!DOCTYPE html>
<html lang="en">
<head>
    <meta charset="UTF-8">
    <meta name="viewport" content="width=device-width, initial-scale=1.0">
    <title>İntihal Kontrol</title>

</head>
<body>
    <h1>İntihal Kontrol</h1>

    <form action="/upload" method="POST" enctype="multipart/form-data">
        <label for="mainfile">Tek Dosya Seç:</label>
        <input type="file" id="mainfile" name="mainfile" accept=".txt" onchange="updateSubmitButton()">
        <br><br>

        <label for="otherfiles">Birden Fazla Dosya Seç:</label>
        <input type="file" id="otherfiles" name="otherfiles" accept=".txt" multiple onchange="updateSubmitButton()">
        <br><br>

        <button type="submit" id="submit-button" >Gönder</button>
    </form>
</body>
</html>
```

4.2 Route Methodu ile Sayfa Yönlendirmeleri

Hazırladığımız **index.html** sayfasını, web uygulamasının **anasayfası** olarak ayarlamak için app.py dosyamız içinde **@app.route('/')** dekoratörü ile tanımlayacağımız index fonksiyonu içinde Flask'in **render_template** fonksiyonuna html sayfamızı göndererek, sayfamızı uygun şekilde işleyip isteği işlenmiş html sayfası ile yanıtlamasını sağladık.

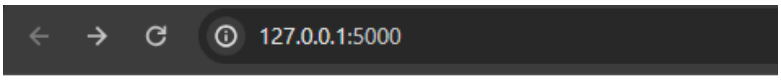

İntihal Kontrol

Tek Dosya Seç: Dosya Seç Dosya seçilmedi

Birden Fazla Dosya Seç: Dosyaları Seç Dosya seçilmedi

Gönder

4.3 Yüklenen Dosyaların İşlenmesi

Index sayfasındaki form üzerinden POST methoduyla gönderilen dosyaları /upload'ta alıp gerekli kontrolleri yaptıktan sonra anlamlı verilere çevirecek şekilde okuyan fonksiyonlara gönderdik. Daha sonra kontrol fonksiyonunu çalıştırarak sonucu main ve other değişkenlerine atadık. Ve sonucu göstermek üzere render_template fonksiyonuna result.html dosyasını main-other (asıl dosya ve kaynak metinler) değişkenleriyle çalıştırıyoruz.

```
@app.route('/upload', methods=['GET', 'POST'])
def upload():
    if request.method == 'POST':
        mainfile = request.files.get('mainfile')
        otherfiles = request.files.getlist('otherfiles')

        if not mainfile and not otherfiles:
            return render_template('index.html', error='Dosya seçilmedi.')

        if mainfile and  '.' in mainfile.filename and mainfile.filename.rsplit('.', 1)[1].lower() in ["txt"]:
            main_content = mainfile.read().decode('utf-8')
            dosya_oku(main_content)

        others_contents = []

        for file in otherfiles:
            print(file.filename)
            others_contents.append(file.read().decode('utf-8'))

        dosyalar_oku(others_contents)
        main, other = kontrol()
        return render_template('result.html', main=main, other=other)

    return render_template('index.html')
```

4.4 Kontrol Edilmiş Metinleri HTML Formatına Uygun Hale Getirme

Kontrol fonksiyonu ile işlenmiş ve gerekli işaretlemelerin yapıldığı metinleri result.html sayfasında uygun ve ayırt edici şekilde görüntülemek üzere **html_format** isminde bir fonksiyon yazıldı. Dosya numarasını alıp ona göre sonuç döndüren bu fonksiyon, -1 numaralı dosyayı (asıl metin), intihal tespit edilmiş kelimeleri kırmızı renkle işaretlenmiş şekilde, yeni satırları
 etiketiyle göstererek tüm metni html formatında döndürür.Eğer dosya numarası -1 değilse, kaynak dosyaları listesinden ilgili indisteki metni alır ve benzer işaretlemeleri yaparak html metnini döndürür.

```
def html_format(fileid):
    if fileid == -1:
        main_html = []
        text_len = len(main_text)
        plag_count = 0
        for word in range(text_len):
            if main_gui[word][1] == False:
                main_html.append(main_gui[word][0] + " ")
            else:
                main_html.append('<span style="color:red;">{}</span> '.format(main_gui[word][0]))
                plag_count += 1
            if main_gui[word][2] == True:
                main_html.append("<br>")
        return "".join(main_html)
    else:

        comp_text = []
        lenn = len(source_gui[fileid])
        print(source_gui[0])
        for word in range(lenn):
            if source_gui[fileid][word][1] == False:
                comp_text.append(source_gui[fileid][word][0] + " ")
            elif source_gui[fileid][word][1] == True:
                comp_text.append('<span style="color:red;">{}</span> '.format(source_gui[fileid][word][0]))

            if source_gui[fileid][word][2] == True:
                comp_text.append("<br>")
        return "".join(comp_text)
```

kontrol fonksiyonunun dönüş değerleri olarak html_format fonksiyonuna iki dosya indisi gönderilerek işlenmiş çıktılar atandı. Test amaçlı ilk indis asıl dosya, ikinci indis kaynak dosyalarından ilki olarak verildi. Basit bir html sayfası test için hazırlandı.

```
def kontrol():
    N = 3 # varsayılan değer, daha sonra kulla
    n = N - 1 # N sayının bir eksiği, eklenece
    main_N= main_text[:N-1].copy() # ilk N-1 k
    main_len = len(main_text)
    for id in range(main_len - n):
        main_N.append(main_text[id + n]) # mai
        for file_id in range(len(source_texts)
            for j in range(len(source_texts[fi
                if main_N == source_texts[file
                    for k in range(N): # N kad
                        main_gui[id + k][1] =
                        source_gui[file_id][j
        main_N.pop(0) # main_N listesinin ilk
    return html_format(-1), html_format(0)
```

```
<!DOCTYPE html>
<html lang="tr">
<head>
    <meta charset="UTF-8">
    <meta name="viewport" content="width=device-width, initial-scale=1.0">
    <title>İntihal Kontrol - Sonuç</title>
</head>
<body>
    <h1>İntihal Kontrol - Sonuç</h1>
    <h2>Asıl Metin</h2>
    {{ main | safe}}
    <br>
    <h2>Karşılaştırma Metni</h2>

    {{ other | safe}}
</body>
</html>
```

4.5 Web Uygulamasının İlk Kurulum Çıktısı

Flask ile basit bir web sunucusu üzerinde daha önce yazdığımız fonksiyonların işlevselliğini, çalıştırarak sadece bir tasarımla birleştirdik. Sonuç istediğimiz gibi oldu. İntihal tespit edilen kelimeler kırmızı olarak işaretlendi. Yaklaşık 1000 karakterden oluşan bir metin dosyası ile toplamda yaklaşık 55 bin karakter içeren 4 farklı metin dosyasını neredeyse anında kontrol ederek sonucu yazdırdık.

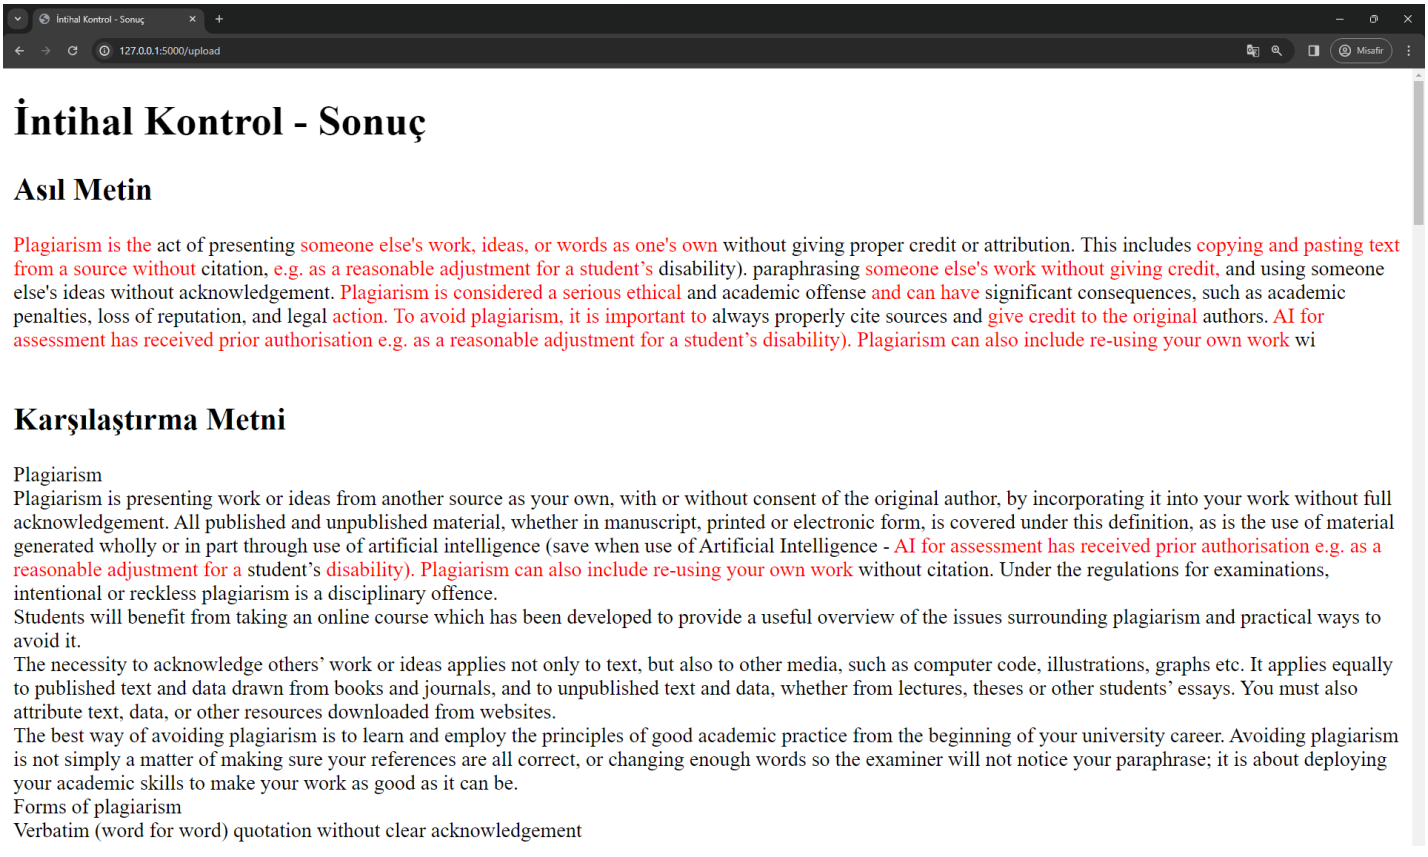

5. Web Uygulamasının Kullanıcı Arayüzünü Geliştirme

5.1 Anasayfa

Uygulamanın arayüzünü daha kullanışlı ve estetik yapmak için Bootstrap kütüphanesi ve özel JavaScript kodları kullanıldı. Kontrol edilecek dosyayı yüklemek için bir alan, kaynak olarak kullanılacak dosyları seçmek için başka bir alan oluşturuldu. Dosyaların sürükle-bırak şeklinde eklenebilmesi için JavaScript kullanıldı. Ayrıca kaç ardaşık kelime benzerliğinin intihal sayılacağını kullanıcının seçebilmesi için bir seçici eklendi.

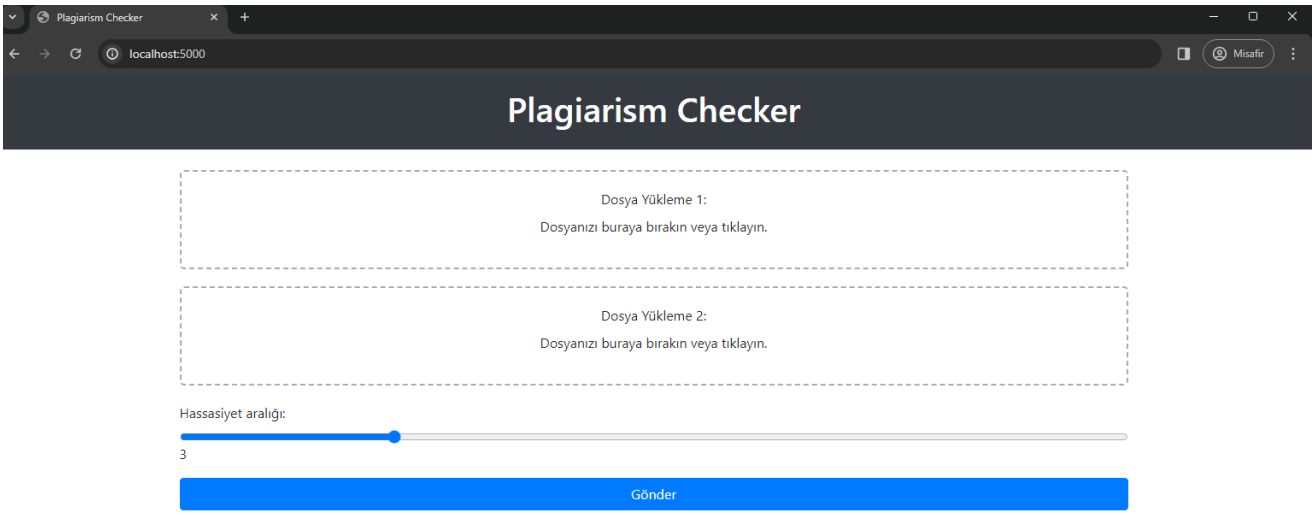

Bu sayfa hem görsel olarak yeniden tasarlandı, hem de önemli birkaç işlevsel özellik eklendi. İntihal oranını gösteren bir bar, farklı bir tekrar sayısına göre yeniden kontrol çalıştırmak için bir seçici ve bir buton, asıl metin ve karşlaştırılan metinleri içeren metin kutuları, karşılaştırılan metni seçebilme için bir açılır menü eklendi. Ayrıca kontrol ve html_format fonksiyonlarında birkaç değşikilik yapılarak, her kelimenin intihal olarak işaretlenmesine sebep olan karşılaştırma metnindeki karşılığınının kolayca bulunabilmesine yardımcı olacak bir özellik eklendi. Asıl metinde kırmızı ile yazılı olan metinlere eklenen özel linkler (bağlantılar) sayesinde, tıklandığında ilgili metnin ilgili kelimesine yeşil ile işaretlenip ekranda gösterilmesi sağlandı.

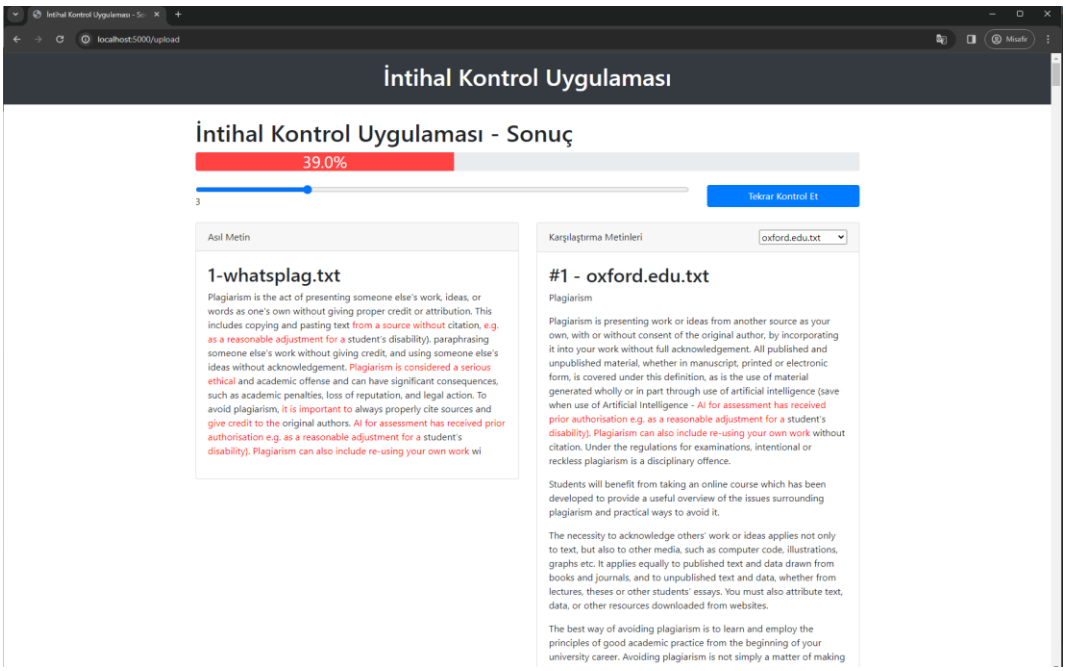

5.3 İntihal Oranını Gösteren Bar

html_format fonksiyonunda intihal olarak görülen kelimelerin toplam kelime sayısına bölümüyle elde edilen plag_ratio değişkeni, toplam intihal oranını göstermesi için daha sonra result.html'e gönderildi.
result.html içinde is basit bir html kodu ile gösterildi.

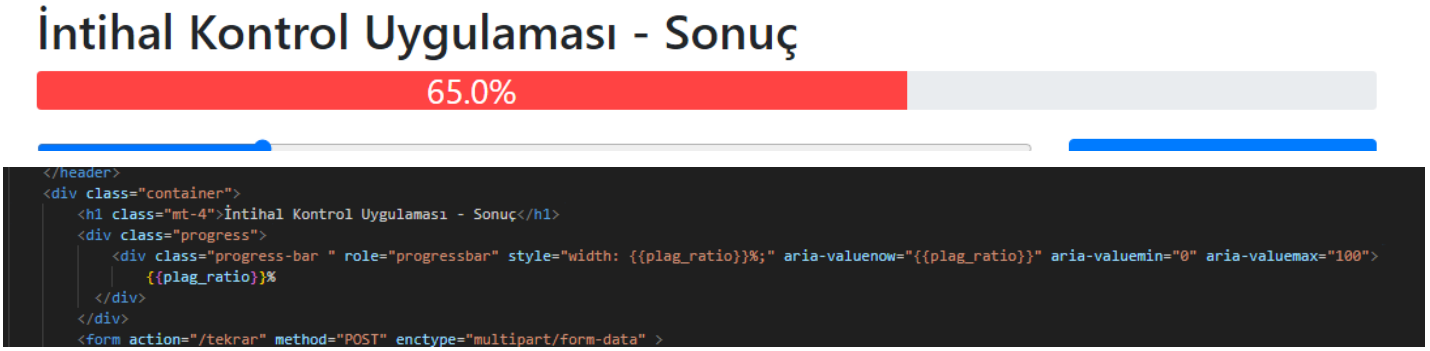

5.4 Yeniden Kontrol Formu

Kullanıcının aynı metinleri sadece farklı bir N değeri ile tekar kontrol edebilmesini sağlamak amacıyla tekrarKontrol Fonksiyonu yazıldı. Bu fonksiyon verilen N değeriyle kontrol fonksiyonunu tekrar çalıştırmayı sağlar. Ayrıca önceki intihal işaretlerini sıfırlamak için deleteGui fonksiyonu ile tüm kelimeler tekrar 'intihal yok'(0, False) olarak işaretlendi.

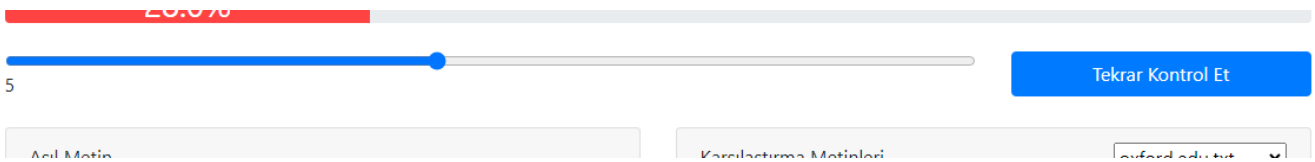


```
def deleteGUI():
    for word in main_gui:
        word[1]=False
    for file in  (source_gui):
        for word in file:
            word[1]=0

@app.route('/tekrar', methods=['GET', 'POST'])
def tekrarKontrol():
    print(main_text)
    if request.method == 'POST':
        deleteGUI()
        N = int(request.form.get('N'))
        result = kontrol(N)
        return render_template('result.html', result=result, files=file_dict, mainfile=mainfilename, plag_ratio=plag_ratio//1, N=N)
```

5.5 Metin Kutuları

Kullanıcının yüklediği asıl ve kaynak metinlerini görebilmesi, intihalleri metin içinde görebilmesi için yan yana iki metin kutusu hazırlandı. Karşılaştırma metinleri kutusuna, metinler arasında geçiş yapabilmek için bir açılır menü eklendi. İlk sorgu sonucunda tüm metinler gösterilirken, daha sonraki kullanıcı seçimlerine bağlı olarak sadece seçilen metin kalacak şekilde yeniden düzenlenir. Bu özellik için CSS ve Javascript kullanıldı.

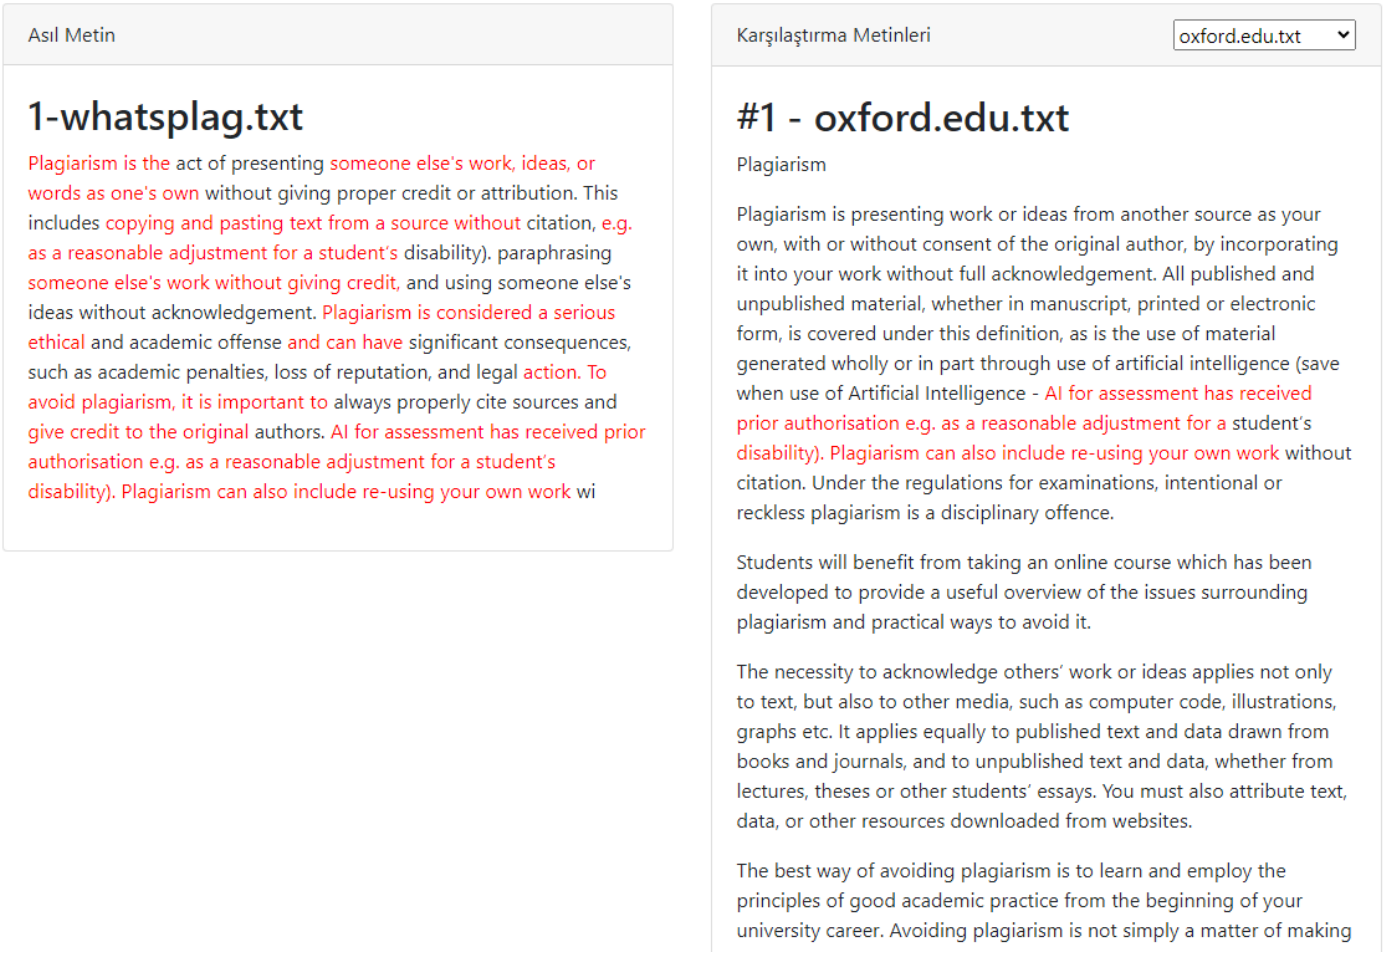

5.6 İntihal Kaynağını Bulma

Bu eklenen özellik sayesinde intihal işaretlenmesine sebep olan karşılaştırma metinlerindeki kelimelere, dosya id ve kelime id olarak birer kimlik atandı. Ayrıca asıl metindeki kelimelerde ise intihal tespitleri sırasında ilgili karşılaştırma metnindeki kelimenin kimliği saklandı. Daha sonra bu kimlikler html hash linklerde kullanılarak javascript yardımıyla ilgili metnin sayfaya getirilmesi, ilgili kelimenin sayfada gösterilecek şekilde kaydırma yapılması, ilgili kelimenin yeşil ile işaretlenmesi sağlandı.

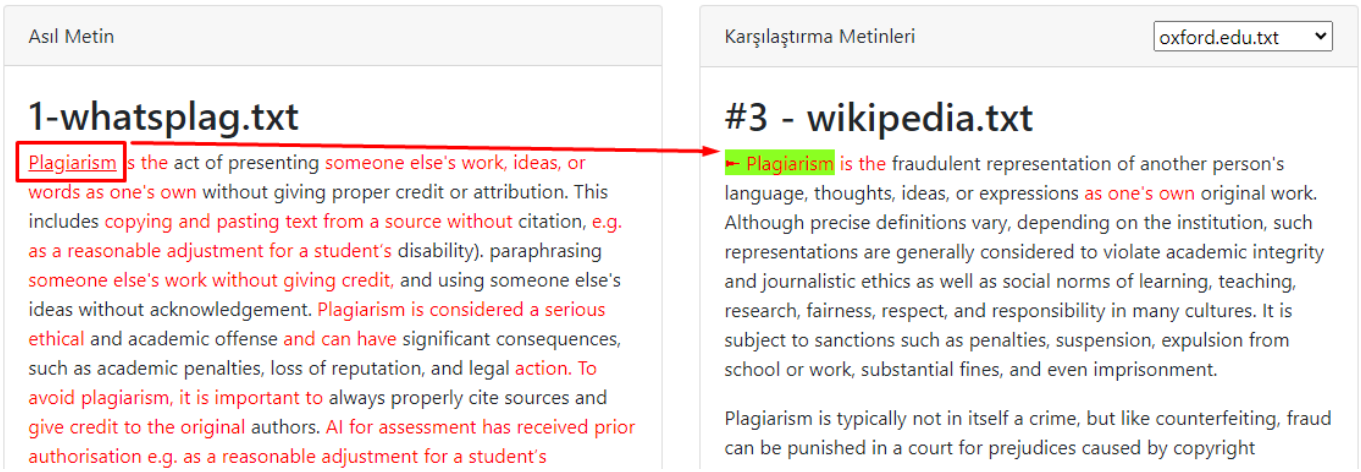

```python
def kontrol(N):
    n = N - 1 # N sayının bir eksiği, eklenecek kelime ilk kelimeden N-1 kelime sonraki kelime olacaktır
    main_N= main_text[:N-1].copy() # ilk N-1 kelimeyi main_N listesine ekliyoruz, N tane eklememe sebebimiz sonraki kelimenin döngüde eklenecek olmasıdır
    main_len = len(main_text)
    for id in range(main_len - n):
        main_N.append(main_text[id + n]) # main_N listesine sonraki kelimeyi ekliyoruz
        for file_id in range(len(source_texts)): # dosya sayısı kadar döngü
            for j in range(len(source_texts[file_id]) - n): # dosyadaki kelime sayısı-1 kadar döngü
                if main_N == source_texts[file_id][j:j + N]: # eğer main_N listesi, kaynak kelime listesinin ardışık N kelimesine eşitse
                    for k in range(N): # N kadar döngü şeklinde her kelimeyi işaretliyoruz
                        main_gui[id + k][1] = True # main_text'in arayüz için kullanılacak dönüştürülmemiş halini içeren listede, kelimenin 1. indisi True değerini(intih
                        main_gui[id + k][2] = [file_id, j + k] # main_text'in arayüz için kullanılacak dönüştürülmemiş halini içeren listede, kelimenin 2. indisi, intiha
                        source_gui[file_id][j + k][1] = True # kaynak kelime listesinin arayüz için kullanılacak dönüştürülmemiş halini içeren listede, kelimenin 1. indi
        main_N.pop(0) # main_N listesinin ilk elemanını çıkarıyoruz, böylece yeni kelime eklenebilir hale geliyor
    return [ html_format(i) for i in range(-1, len(source_gui))]
```

```python
def html_format(fileid):

    if fileid == -1:
        main_html = []
        text_len = len(main_text)
        main_html.append("<p> ")
        plag_count = 0
        word_count = 0
        global plag_ratio
        for word in range(text_len):
            if main_gui[word][1] == False:
                main_html.append(main_gui[word][0] + " ")
                word_count += 1
            else:
                main_html.append('<a href="#w{}-{}" style="color:red;">{}</a> '.format(main_gui[word][2][0]+1 , main_gui[word][2][1], main_gui[word][0]))
                plag_count += 1
                word_count += 1
            if main_gui[word][2] == True:
                main_html.append("</p><p>")
        plag_ratio = (plag_count / word_count) * 100
        return "".join(main_html) # metnin başına ve sonuna <p> tagı ekler
    else:
        comp_text = []
        lenn = len(source_gui[fileid])
        comp_text.append( "<h2>#{} - {}</h2>  <p> ".format(fileid +1,file_dict[fileid]))
        for word in range(lenn):
            if source_gui[fileid][word][1] == 0:
                comp_text.append(source_gui[fileid][word][0] + " ")
            elif source_gui[fileid][word][1] == 1:
                comp_text.append('<span id="w{}-{}" style="color:red;">{}</span> '.format(fileid+1,word,source_gui[fileid][word][0]))
            if source_gui[fileid][word][2] == 1:
                comp_text.append("</p><p>")
        return "".join(comp_text)
```

Projenin canlı versiyonunu denemek için https://plgtest.vercel.app/ adresini ziyaret edebilirsiniz.